

MapReduce-System

NVS Projekt 2

Alexander Grill 5CHIF 12. April 2021

Informatik HTBLUvA Wr.Neustadt Österreich

Inhaltsverzeichnis

1	\mathbf{Ein}	führung	2
	1.1	Vorwort	2
	1.2	Motivation	3
2	Auf	gabenstellung	3
	2.1	Erläuterung der Aufgabenstellung	3
	2.2	Idee	4
	2.3	Themenbereiche	4
3	Gru	ındlagen	5
	3.1	Was ist ein MapReduce System?	5
	3.2	Map und Reduce	5
	3.3	Ablauf	6
	3.4	Vorteile und Nachteile eines Map-Reduce Systems	7
	3.5	Parallel Programming	8
	3.6	Kommunikation	13
	3.7	$TCP/IP \ \dots $	20
4	Imp	olementierung	23
	4.1	Projektstruktur	23
	4.2	UML Klassendiagramm	25
	4.3	Client	26
	4.4	SlaveServer	28
	4.5	MasterServer	30
	4.6	utils	33
	4.7	Konsolenausgabe	36
	4.8	Verwendete Bibliotheken	38
		4.8.1 asio	38
		4.8.2 CLI11	39
		4.8.3 spdlog	40
		4.8.4 json	40
		4.8.5 rang	40
		4.8.6 tabulate	41
5	Anv	vendungsfälle	41
6	Sch	lusswort	43

1 Einführung

In diesem Kapitel werden die Gründe der Umsetzung und das Thema, worum es in dieser Arbeit geht, genau erläuter. Es wird auch darauf eingegangen, welche Thematiken das Projekt umfassen soll und wie sich die Benotung auseinandersetzt.

1.1 Vorwort

Der Virus "COVID-19" war im Jahr 2020 für die gesamte Bevölkerung auf der Erde eine riesengroße Herausforderung. Die Situation änderte sich am Begin des darauffolgenden Jahres 2021 nicht. Deshalb beschloss die Bundesregierung weitere Maßnahmen, Ausgangsbeschränkungen, Grenzkontrollen, FFP2-Maskenpflicht und weitere Regeln einzuführen die die Bevölkerung einzuhalten hat. Alle Schüler in Österreich müssen die Schule blockweise besuchen. Nur mit einem davor verpflichtetenden Schnelltest und FFP2-Masken dürfen sie die Schule betreten. Da die Projektarbeiten im ersten Semster entsprechend gut ausgefallen sind, beschloss Herr Professor Kolousek, dass Schüler in den fünften Klassen im Fach NVS statt der Praktischen Arbeit und dem Theorietest eine Projektarbeit über den Semsterstoff machen müssen. Folgenddessen muss die Dokumentation über das gewählte Thema dementsprechend einen weiteren Umfang umfassen, als beim ersten Projekt im ersten Semster. Im praktischen Teil geht es in diesem Projekt darum, ein Map-Reduce System in Kombination mit Server-Client Kommunikation zu implementieren. Im theoretischen Teil werden die Grundlagen, die für die Umsetzung relevant sind, erklärt. Zusätzlich beinhaltet dies auch sämtliche Abschnitte, wie die Source Code Dokumentation, Abläufe, Erklärung bezüglich MapReduce-System, Aufbau und Anwendungsfälle.

Die zu erreichende Note hängt prinzipiell ab von der

- Beispielkategorie
- Art der Kommunikation
- Funktion, Umfang und Tiefe der Implementierung
- Fehlerbehandlung
- Ausgaben, Einhaltung der Coding Conventions, Kommentare
- Repository: Commits, Issues
- Ausarbeitung
- Einhaltung der Richtlinien

1.2 Motivation

In diesem NVS Projekt geht es darum, ein MapReduce-System mit der Programmiersprache C++ unter Linux mittels g++ Compilier umzusetzten. Kurz zusammengefasst soll eine große Menge an komplexen, unstrukturierten und eine Art von aufwendigen Daten verarbeitet werden. Das heißt, es sollen Daten, die planlos abgespeichert sind, zusammengefasst werden, sodass diese wieder ihren Nutzen oder Sinn erbringen. Diese können dann für weiter Verarbeitungsschritte oder Datenanalysen verwendet werden. Die Daten werden am Beginn in kleine Pakete aufgeteilt und diese werden mit einem eindeutigen Schlüsse identifiziert. In der nächste Phase werden die einzelnen Pakete parallel von unterschiedlichen, getrennten und unabhängigen Prozessen zusammengefasst. Danach werden die gruppierten Daten wieder einem Schlüssel zugeordnet, sodass diese wieder zusammengefasst und minimiert werden. Die Kommunikation zwischen den einzelnen Knoten soll in dieser Arbeit mittel Server-Client Kommunikation passieren. Der Server hört auch einen Port ab, ob sich ein Client damit verbinden möchte. Wenn eine Verbindung aufgebaut werden kann, soll die Splittung der Daten passier, daraufhin soll das Resultat weiter an den Server gegeben werden, bis alle Daten vereint auf dem Master Server liegen. Die bearbeiteten Daten werden schlussendlich in einem JSON-File abgespeichert.

2 Aufgabenstellung

Dieses Kapitel umfasst die genaue Erläuterung der Aufgabenstellung, sowie die Themenbereiche dieser Projektarbeit. Darüber hinaus wird auch über die Idee der Umsetzung geschrieben.

2.1 Erläuterung der Aufgabenstellung

Ziel ist es, dass eine Menge von unstrukturierten Daten so verarbeitet werden, dass diese danach wieder in ordnungsgemäßer Struktur vorliegen. Zuerst müssen die Daten aufgeteilt werden. Sie werden in einer Key-Value Form abgepeichert, somit kann der Value, also der abgespeicherte Datensatz, mittels Key eindeutig identifiziert werden. Nachdem die Daten zusammengefasst vorliegen, werden sie im nächsten Schritt auf einzelne Knoten aufgeteilt. Diese erlangen von den einzelenen Clients die Daten in Key-Value Form und fassen diese wieder zusammen, bis die Daten zu einem Master Knoten ankommen und dort schlussendlich in geordneter Form darliegen. Die Aktionen der Datenverarbeitung verlaufen ständig unter paralleler Abfolge. Die Aufgaben werden aufgeteilt und laufen auf verscheidenen Knoten.

2.2 Idee

Das Projekt ist so aufgebaut, dass es acht oder mehr Clients gibt, zwei Slave Server und einen Master Server. Ein Benutzer (Client) kann eine beliebige Anzahl von Zeichenketten, die er dem Programm beim Aufruf mitübergibt, erzeugen und diese werden dann in einer Datei abgespeichert. Zusätzlich wird dem Benutzer auch angeboten, den Speicherort der Datei selbst auszuwählen. Nachdem die ungeordneten Daten in einer Datei abspeichert sind, beginnt die nächste Phase des Map-Reduce Systems. Die Datei wird zeilenweise durchgegangen. Die Zeichenketten werden in einem Art Dictionary als Key-Value Form abgespeichert, dadurch kann jeder eingefügte Datensatz identifiziert werden. Wenn der Datensatz in diesem Dictionary schon existiert, dann wird der Value, der als Counter festlegt, wie oft die Zeichenfolge im Text vorkommt, um eins erhöht. Nachdem kompletten Durchlauf der Datei sind alle Daten in diesem Dictionary abgespeichert. Dadurch, dass mehrere Clients das System zum gleichen Zeitpunkt unabhängig voneinander nutzen können, wird das Durchforsten der Datei von anderen Prozessen nicht beeinflusst. Nachdem ein Prozess mit der Datenabspeicherung fertig ist, sendet er die Daten an den jeweiligen Slave Server, der zu diesem Zeitpunkt nicht beschäftigt ist. Wenn der Server von einer gewissen Anzahl von Clients die Daten bekommt, beginnt er danach mit der Map Phase. An dieser Stelle werden die gesendetetn Daten wieder per Key zusammengefasst und strukturiert. Die Abarbeitung erfolgt auch in diesem Fall parallel zu einem weiteren Slave Knoten, der die selbe Art und Weise der Datenverarbeitung nutzt. Schlussendlich wird das Result an den Master Server geschickt. Jetzt bringt dieser all seine empfangenen Daten in eine Struktur, die im Nachhinein für Datenanalysen eingesetzt werden können.

2.3 Themenbereiche

Diese Arbeit umfasst folgende Thematiken

- Grundlagen und Basiskonzepte, Nachrichtenübertragung, Netzarchitektur
- Internetprotokoll
- Transportprotokolle
- Prozesse und Threads
- Synchronisation und parallele Programmierung
- Kommunikation, Serverprogrammierung, verteilte Systeme
- TCP/IP Programmierung

3 Grundlagen

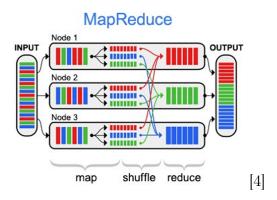
3.1 Was ist ein MapReduce System?

Das Verfahren wurde 2004 von Google für die Indizierung von Webseiten entwickelt. Das Framework wird bei Datenbanken eingesetzt und dient zur Verarbeitung von großen, komplexen, unstrukturierten Datenmengen. Dieses Verfahren findet Anwendung für BigData und Datawarehouse, weil in solchen Fällen große Datenmengen in kürzester Zeit mittels Software verarbeitet, analysiert, aggregiert als auch kompremiert werden. Map Reduce parallelisiert die Bearbeitung durch die Verteilung auf mehrere gleichzeitig auszuführende Tasks. Der Grund, warum dieses Framework solche Datenmengen verarbeiten kann ist, weil die Aufgaben auf mehrere Rechnern aufgeteilt werden. Jeder einzelne Rechner startet Prozesse, die parallel die Daten verarbeitet und auswertet. Ein einzelner Rechner stößt schnell an seine Grenzen, deshalb ist die Verarbeitung von Daten mittels mehreren Knoten sehr effizient und bietet eine bessere Performance. Das Verfahren wurde in vielen verschiedenen Verfahren eingesetzt, wie zum Beispiel für die Indizierung von Webseiten, nach einer Suchanfrage mit beliebigen Zeichenketten. Auch im Umfeld von Google News wird MapReduce verwendet. Andere große Internetfirmen wie Yahoo, die ebenfalls das Verfahren für die Indexierung von Webseiten verwenden, als auch Facebook verwendet das System, um Spam Messages zu minimieren und die Ads zu optimieren. Amazon hingegen verwendet das Verfahren für das Clustering der Produket. Ein Cluster ist eine Gruppe von Objekten mit ähnlichen Eigenschaften. Im technischen Bereich werden Cluster dazu genutzt um Produkte, Einzelteile oder Baugruppen nach bestimmten Gesichtspunkten zu gruppieren.

3.2 Map und Reduce

Die beiden Grundfunktionen des Verfahrens sind Map und Reduce. Sie sorgen für die Aufteilung der Aufgaben in kleinere parallelisierte Arbeitspakete und führen am Ende die Ergebnisse zusammen. Bei großen relationalen Datenbanken und komplexen Queries lassen sich typische Probleme, bezüglich Verarbeitung von großen Datenmengen beseitigen. Die Map Funktion verteilt die Aufgaben an unterschiedlichen Knoten eines Clusters. Die Reduce Funktion sortiert die verfassten Ergebnisse und fügt sie am Ende wieder zusammen. Die Funktionen Map und Reduce werden vom User bereitgestellt, weil diese schließlich zu den bereitgestellten Daten passen müssen. [13]

3.3 Ablauf



Das Verfahren verläuft durch folgende Schritte:

• Split

 Die bereitgestellten Daten werden aufgeteilt. Jeder Datensatz darin ist durch einen Schlüssel-Wert identifiziert. Diese Datenmenge wird nun in kleinere Datenmengen aufgeteilt und vom Master an die verfügbaren Knoten verteilt.

• Map

 Nun wendet jeder Knoten auf die Daten die Map-Funktion an, die schließlich Key/Value Paare zurückgibt. Diese Ergebnisse werden zwischengespeichert.

Shuffle

- Bei diesem Schritt geht es darumm denn reduce-Knoten die entsprechenden Daten zuzuteilen. Diese Zuteilung entspricht einer Fragmentierung. Hierbei wird dem Knoten, die reduce ausführen, ein Key zugeteilt. Diese Knoten holen sich dann die bereits durch Map entstandenen Datensätze mit diesem Key und wenden reduce an.

• Reduce

– Grundsätzlich ist die Aufgabe dieser Funktion die Key/Value Paare anhand des Schlüssels zusammenzufassen und dabei die Summe der einzelnen Values zu bilden. Demnach ist die Ausgabe der Reduce-Funktion wieder ein Key/Value Paar mit dem gleichen Aufbau wie vor der Verarbeitung. Dies ermöglicht es, dass reduce mehrere Male angewendet werden kann, bis schließlich alle Daten gesammelt wurden.

3.4 Vorteile und Nachteile eines Map-Reduce Systems

Map Reduce bietet eine Menge an Vorteilen gegenüber dem klassischen Verfahren der Datenverarbeitung, wie sie in den relationalen Datenbanksystemen verwendet werden.

Ein wesentlicher Vorteil ist, dass für die Verwendung eines solchen System ein einfacher normaler Rechner benötigt wird und keine Highend-Server. Ein Cluster-Verbund für die parallelisierte Datenverarbeitung kann bei Notwendigkeit ohne großen Aufwand realisiert werden. Ein Cluster-Verbund ist ein Netzwerk, das aus mehreren Rechner besteht, die gleichzeitig miteinander verbunden sind und Daten austauschen. Aus diesem Grund ist ein MapReduces-System sehr kostensparend und kann mit wenig Know-How und Erfahrungen umgesetzt und schlussendlich in Verwendung gebracht werden.

Ein weiterer Vorteil ist auch die Skalierbarkeit. Da die Daten auf den jeweiligen Knoten aufgeteilt werden, bietet das System eine zuverlässige Ausfallstoleranz und Verfügbarkeit, denn wenn ein Knoten ausfallen sollte, werden die Daten einfach an einen anderen Knoten weitergeleitet und dort verarbeitet, somit läuft das System jederzeit in einem stabilen Zustand.

Durch die parallelisierte Verarbeitung von Daten ist dieses Verfahren deutlich effizienter und perfomanter als die Datenverarbeitung in relationalen Datenbanken. Im Terabyte-Bereich dauert das Verfahren oft nur Minuten, im Petabyte-Bereich Stunden, wobei andere Systeme deutlich mehr Zeit und Ressourcen für die Verarbeitung benötigen.

Während die Berechnungen schnell gehen, dauert der Datenzugriff länger als bei anderen Methoden. Die Daten müssen erst über das Netzwerk gestreamt werden. Dabei ist die Netzanbindung der Flaschenhals, vor allem im Hinblick auf die sehr unterschiedlichen Rechner innerhalb des Clusters und deren unterschiedliche schnelle Netzanbindung.

Um die Geschwindigkeit zu erhöhen, kann ein Cluster ausschließlich aus High-End-Servern bestehen. In diesem Fall sind die Kosten für das MapReduce-Verfahren immens hoch. [2]

3.5 Parallel Programming

Unter Parallel Programming versteht man die Aufteilung einer Problemstellung in weitere kleinere Teilprobleme, die nebenläufig abgearbeitet werden. Dabei wird jedes Teilproblem einzeln gelöst und dadurch kann auch das Gesamtproblem effizient und schnell gelöst werden.

Gleichzeitig kann die Problemstellung schneller gelöst werden, weil die Abarbeitung aufgeteilt wird und die Teilprobleme unabhängig voneinander gleichzeitig bearbeitet werden können. Parallel Programming wird heutezutage in Branchen wie Chemie, Biologie, Medizin, Maschinenbau, Baustatik, Simulationen, Suchen in großen Datenbestände etc. angewendet.

Mooresches Gesetz

"Die Anzahl der Transistoren pro Chip verdoppelt sich etwa alle zwei Jahre". Das heißt, je mehr Transistoren sich auf einem Chip befinden, desto mehr Funktionalität kann parallel abgearbeitet werden. Laut der Webseite "nature.com"wird die Halbleiterindustrie im März 2016 anerkennen, dass Moore's Law nicht mehr eingehalten werden kann. Demnach werden Chips nicht mehr zwangsläufig schneller, aber Fortschritt und Effizienzmaximierung wird es weiterhin geben.

Wirth 'sches Gesetz

"Die Software wird schneller langsamer, als die Hardware schneller", darunter versteht man, dass die Anforderungen an die Software immer aufwendiger, größer und komplexer wird und die Hardware diese Softwaren sehr langsam bis gar nicht verarbeiten können.

Taktfrequenzen

Die Taktfrequenze verdoppelte sich in den 1990-er Jahre alle 18 bis 20 Monate, aber seit 2000 bis 2005 ist das nicht mehr der Fall. Heute finden maximial 4GHz im Desktop und Serverbereich Anwendung.

Man spricht von einer sogenannten "Frequency Wall", wenn die Taktfrequenz nicht mehr erhöht werden kann, weil höhere Frequenz höhere Spannung bedeutet, höhere Spannung heißt, höhere Verlustleistung. Das hat zur Folge, dass die entstehende Wärme, die durch den Anhieb der Taktfrequenz und durch die Datenverarbeitung entsteht, nicht mehr abgeführt werden kann. Existierende nicht parallelisierte Software profitiert nicht mehr automatisch von der Leistungssteigerung der Hardware. Ein weiterer Nachteil ist, dass das Laufzeitverhalten paralleler Algorithmen schwieriger nachvollziehbar sein kann, als das eines äquivalenten sequentiellen Algorithmus.

Lösungsansätze

Der einfachste Lösungsansatz ist der, indem man den Problemraum einschränkt. Damit ist gemeint, der Algorithmus wird für den jeweiligen Aufwand eingeschränkt und angepasst. Eine weitere Idee wäre, dass man den Algorithmus selbst optimiert, jedoch ist das nicht immer möglich. Weiters ist die Verbesserung der Implementierung von Vorteil. (z.B Facebook -> eigener String) Auch durch den Bereich Hardware kann eine Software verbessert werden, dennoch ist diese Strategie mit hohen Kosten verbunden. Am effizientesten ist es hingegen, die Software in Teilprobleme aufzuteilen und diese parallel abzuarbeiten. Da ein Prozessor mehrere Kerne besitzt, können mehrere unterschiedliche, unabhängig voneinander, Prozesse abgearbeitet werden.

Möglichkeiten der Parallelisierung

- Zerlegung der Gesamtaufgabe in kleinere, mehrere Teilaufgaben, sodass die maximale Auslastung aller Prozesser(HW) stattfindet, weil jede Teilaufgabe auf einem einzelnen Prozessor stattfindet.
- Zerlegung der Gesamtaufgabe in kleinere, mehrere Teilaufgaben, die hintereinander ausgeführt werden, allerding wird die Gesamtzeit der Lösung einer Gesamtaufgabe nich kürzer und der Durchsatz bei der Lösung von vielen Aufgaben höher.
- Zerlegung der Gesamtaufgabe in kleinere, mehrere Teilaufgaben, die hintereinander ausgeführt werden, aber mit spezieller Hardware gelöst werden.

Pipelinig

Pipelinig beschreibt den Vorgang wie ein Prozessor vorgeht, wenn er mehrere Befehle verarbeiten muss. Als Erstens wird der Befehl aus dem Arbeitsspeicher geladen(fetch), weiters wird dieser Befehl in Maschinensprache umgewandelt und dekodiert(decode). Werden zusätzliche Daten benötigt, lädt der Prozessor diese aus Registern oder aus dem Arbeitspeicher. Folgedessen wird der Befehl ausgeführt(execute) und das Resultat des Befehls wird in einem Register oder im Arbeitspeicher geschrieben (write back). Die einzelnen Schritte werden in einer eigenen Hardwarekomponente ausgeführt, deshalb ist es möglich, wenn ein Befehl gefetched wird und danach dekodiert werden kann, kann in der Zeit, in der er dekodiert wird, ein andere Befehl gefetched werden, weil die Hardwarekomponente nicht verwendet wird. Das ist bei jedem einzelnen Schritt beim Pipelinig möglich. Die Abarbeitungzeit der einzelnen Prozesse wird nicht minimiert, hingegen können mehrere Prozesse in einer Zeitspanne abgewickelt werden, d.h. der Durchsatz ist höher.

Probleme

Befehle, zwischen denen Abhängigkeiten herrschen, können zu Problemen führen. Dabei kann es zu einer längeren Abarbeitung der Prozesse kommen, weil einzelne Prozesse auf das Ergbniss des davor durchgeführten Prozesses warten.

Zusätzlich kann zwischen den Prozessen nicht nur eine Datenabhänigkeit herrschen, sonder auch eine Abhängigkeit im Kontrollfluss. In diesem Fall existiert eine Abhängigkeit zwischen den Prozessschritten selbst. Wie in der Datenabhänigkeit müssen auch hier Wartezyklen eingeführt werden.

Weiters kann auch passieren, dass die Abarbeitungsschritte vom Prozessor selbst umgeordnet werden, obwohl es zwischen den Anweisungen Abhängigkeiten herrschen. Diese werden vom Prozessor nicht berücksichtigt.

Daten, die für einen Prozess benötigt werden, können schon weit vor der Benutzung aus dem Hauptspeicher gelesen werden und schlussendlich auch für die Abarbeitung verwendet werden. Hier kann es zu Problemen kommen, wenn nicht aktuelle Daten oder falsche Daten gelesen werden, weil das Result nicht den gewünschten Wert hat.

Superskalarität

Superskalare Prozesse enthalten mehrere gleichartige Funktionseinheiten, zum Beispiel Rechenwerke für Ganzzahl- und Gleitkommaarithmetik oder Lade- und Speichereinheiten. Damit können mehrere Befehle parallel ausgeführt werden, wenn keine Abhängigkeiten existieren.

Hardware seitiges Multithreading

Wenn mehrere Threads auf ein Szenario warten, können daher in der Zwischenzeit Befehle eines anderen Threads durchgeführt werden, dazu werden aber mehrere Registersätze benötigt. Die Hardwarethreads erscheinen dem Benutzer wie echte Kerne des Prozessors, obwohl sie keine sind. Der Performancegewinn liegt bei ca 10 bis 20%.

Vectoreinheiten

Um die Abarbeitung zu beschleunigen, können sogenannte Vectoreinheiten eingesetzt werden, dabei kann ein Befehl mehrere Daten zur selben Zeit verarbeiten.

Parallele Architekturen lassen sich auf unterschiedliche Arten klassifizieren. Eine sehr grundlegende Einteilung von Computersystemen allgemein stellt "Flynn's Taxonomy" dar. Diese behandelt nicht allein parallele Systeme, beinhaltet diese aber, was verdeutlicht, dass Parallelisierung bereits vor über 40 Jahren ein Thema war.

Eine mögliche Kategorisierung von ausschließlich parallelen Systemen kann nach der Art der Speicherverwaltung getroffen werden. Unabhängig davon, welche Klassifizierung herangezogen wird, ist jedoch zu erwähnen, dass die Übergänge zwischen den Kategorien oft fließend sind. Viele Lösungen sind also durchaus in unterschiedliche Bereichen einzuordnen.

Flynnsche Klassifikation

- SISD single instruction, single data
 - klassische Von-Neumann Architektur
- SIMD single instruction, multiple data
 - Vektorprozessoren
- MISD multiple instructions, single data
 - theoretischer Natur
- MIMD multiple instructions, multiple data
 - Multicore- und Multiprozessorsysteme

Rechnerarchitekt

Man unterscheidet zwischen einem homogenen und einem heterogenen Aufbau. Beim homognenen Aufbau haben alle Rechner die gleichen Hardware-komponenten und beim heterogenen Aufbau haben die Rechner verschiedenartige Prozessoren, Kerne usw.

Bei der Speicherarchitektur gibt es ebenfalls zwei unterschiedlich Arten, nämlich UMA (uniform memory access) und NUMA(none uniform memory access). Bei der UMA Variante haben alle Prozessoren und Kerne Zugriff auf den gleichen Hauptspeicher. Bei der NUMA Variante, besitz jeder Prozess einen eigenen Speicher und der Zugriff auf einen Fremndenspeicher erfolgt über ein Verbindungsnetzwerk.

In der Rechnerarchitektur gibt es Multicore und Multiprozessor. Multi-Core bedeutet, dass in einem Prozessor mehrere Prozessor-Kerne eingebaut sind. Man bezeichnet diese Prozessoren als Multi-Core- oder Mehrkern-Prozessoren. Rein äußerlich unterscheiden sich Multi-Core-CPUs nicht von Single-Core-CPUs. Der Rechenkern ist bei Multi-Core-CPUs einfach mehrfach vorhanden. Innerhalb des Betriebssystems wird der Multi-Core-Prozessor wie mehrere Recheneinheiten behandelt.

Parallelität in der Software

Im Zeitalter exponentiell ansteigenden Datenverkehrs wird der Bedarf an harten und weichen Rechenkapazitäten immer größer. Auch die Rechenprozesse selbst werden deutlich komplexer und erfordern mehr Ressourcen. Eine Antwort darauf ist die Cloud, die der Nachfrage nach Serverleistung mit virtuellen Hostingdiensten nachkommt und so erheblichen Druck von Rechenzentren und Serverlandschaften nimmt. Eine andere Antwort darauf sind Computer, die statt mit nur einem gleich mit mehreren Prozessorkernen ausgestattet werden. Damit schaffen sie ideale Bedingungen für die parallele Programmierung, weil sie eine nebenläufige, sprich parallele, Abwicklung mehrerer Rechenprozesse ermöglichen – so genannte Threads. Dabei spielt es keine Rolle, ob die Teilprozesse auf die Sekunde genau parallel verlaufen – vielmehr geht es darum, dass die Software dadurch verschiedene Dinge gleichzeitig erledigen kann, also die Fähigkeit zum Multitasking besitzt.

Das Amdahl'sche Gesetz

Das Amdahl'sche Gesetz bezeichnet in der Informatik ein Modell zur Beschleunigung von Programmen durch Parallelisierung, deren Voraussetzung bekanntlich die Verwendung mehrerer Prozessoren ist. Verwendet man zum Beispiel doppelt so viele Prozessoren, benötigt man nach Amdahl im besten Fall die halbe Zeit zur Durchführung des Programms aka zur Lösung des Problems. Dabei wird die Temposteigerung allerdings dadurch ausgebremst, dass Programme niemals vollständig parallel operieren können und dass es immer einen gewissen Anteil an sequentiellen Programmteilen geben muss – etwa bei der Initialisierung oder in der Speicherverwaltung, weil diese Dinge entweder auf nur einem Prozessor ablaufen oder in Abhängigkeit zu anderen Ereignissen stehen. Deshalb sieht Amdahl vor, den Programmcode in sortenreine Abschnitte aufzuteilen – solche, die rein sequentiell und solche, die rein parallel operieren. Die komplette Dauer eines Programmes ergibt sich dann aus der Formel Z = zs + zp. Amdahl beobachtet, dass bei steigender Anzahl der Prozessoren dieser Beschleunigungsfaktor (Speed-up) immer stärker von den sequenziellen Anteilen des Prozesses gehemmt wird, da mit der Inbetriebnahme weiterer Prozessoren auch weitere Aufwände anfallen, für die Initialisierung etwa oder für die Synchronisierung, sprich z0. [7]

3.6 Kommunikation

Das Prinzip der Kommunikation im Internet ist, dass man strikt sein soll beim Senden der Daten und tolerant beim Empfangen. Der Zweck einer Kommunikation ist die Interoperabilität, das bedeutet, dass mehrere Systeme, die aus Rechner bestehen, in der Lage sind, Daten untereinander auszutauschen. Die Fehlertolaranz bedeutet, dass die Daten durch festgelegte Regeln übertragen werden aber beim Empfangen in einer gewünschten Form umgewandelt werden können.

Beziehungen zwischen den einzelnen Knoten

- one-to-one
 - Ein Knote kommuniziert mit einenm anderen Knoten
- one-to-many
 - Ein Knoten spricht mit mehreren Knoten und alle lauschen und hören zu. Diese Art von Kommunikation zwischen den Rechnern nennt man multicast
- one-to-any
 - Ein Knoten spricht mit mehreren Knoten, jedoch betrifft das nur einen Knoten von mehreren.
- many-to-one
 - Mehrere Knoten sprechen zu einem konkreten Knoten
- many-to-many
 - Mehrere Knoten kommunizieren mit mehreren anderen Knoten.

Kommunikationsrichtung

Beim Datenautausch ist wichtig festzuhalten, in welche Richtung die Daten übertragen werden. Mittels simplex werden die Daten nur in eine Richtung übertragen. Bei half-duplex werden die Daten ebenso in eine Richtung übertragen, jedoch kann die Richtung in der Übertragung geändert werden. Bei der Variante duplex werden die Daten in beide Richtungen übertragen. Wie im TCP Protokoll realisiert, werden zwei Streams zur Verfügung gestellt, um Daten zu senden und zu empfangen.

Verbindungen

Im Grunde genommen unterscheidet man zwischen verbindungsorientiertern und verbindungsloser Kommunikation. Bei der verbindungsorientierter Kommunikation wird eine Verbindung zwischen zwei Knoten aufgebaut, danach werden Daten ausgetauscht und zum Schluss kommt es zum Verbindungsabbau. Hingegen werden bei der verbindungslosen Kommunikation nur die Datenübertragen und keine Verbindung aufgebaut und abgebaut. Es ist in der Regel effizienter, aber es wird nicht sichergestellt, ob die Daten wirklich beim Empfänger angekommen sind.

Signalisierung

Bei der Kommunikation werden auch Nachrichten ausgetauscht, die zum Aufbau, der Überwachung und dem Abbau einer Verbindung notwendig sind. Man spricht von in-bank signalling. Es wird ein gleicher logischer Kanal wie Nutzdaten und Steuerungsdaten verwendet, oder out-of-band signalling, hier wird ein getrennter logischer Kanal verwendet. Es gibt einen physischen Kanal, der in mehrere logische Kanäle unterteilt ist.

Protokoll

Für die Kommunikation benötigt man auch festgelegte Regeln, die für eine Kommunikation notwendig sind, darunter versteht man den Begriff Protokoll. Das betrifft das Format der Nachrichten, Reihenfolge der Nachrichten und die Spezifikation der Fehlersituation. Es gibt zustandsbehaftete und zustandslose Protokolle. Zustandsbehaftete Protokolle sind jene, bei denen die Nachrichten vom Zustand der zuvor gesendete Nachrichten abhängt. Bei zustandlosen Protokol sind, die Nachrichten unabhängig von zuvor gesendeten Nachrichten.

Session

Im Informationaustausch spielt auch der Begriff Session eine wichtige Rolle. Dieser beschreibt eine feste Beziehung zwischen kommunizierenden Prozessen mit vereinbarten Eigenschaften, wie Namen, Ressourcen, Charakteristika. Dadurch bildet sich ein gemeinsamer Zustand zwischen den einzelnen Prozessen. Um sicherzustellen, welcher Knoten welcher ist und welche Rechte dieser bei der Kommunikation mit anderen hat, werden Mechanismen zu Authentifikation und Autorisierung eingesetzt. Bei HTTP sieht die Kommunikation folgendermaßen aus. Ein Client der mittels Browser eine Seite aufruft sendet einen Request an den Server. Dieser überprüft die Daten der Anfragen und welche Daten der Client benötigt und sendet den Client danach mittels Respones die angefragten Daten zurück.

Wird die Seite neu geladen, so verschwinden auch die Daten, die in einem

Cache zwischengespeichert sind und für weitere Aktionen relevant sind. Dies kann oft zu Problemen führen. Deshalb wird ein sogenanter Session-Cookie verwendet, in dem Daten abgelegt werden, die in einer Session entstehen und für weitere Tätigkeiten relevant sind und in diesem abgespeichert werden.

Hierachie von Protokollen

Protokolle sind hierachisch angeordnet, das hat den Vorteil, dass man mit Problemen zwischen den unterschiedlichen Protokollen besser umgehen kann und jede Schicht nur wissen muss, was mit der darunterliegenden Schicht zu tun ist und wie man Daten an die darüberliegenden Schicht geben kann. Die Schichten können auch ausgetauscht werden.

Kommunikationsstile

Die Kommunikation kann durch unterschiedliche Stilen durchgeführt werden. Zum Beispiel wird ein gemeinsamer genutzter Knoten verwendet und auf diesen zugegriffen, auf dem alle Daten abgespeichert werden, wie es bei Datenbanken der Fall ist. Beim Versenden von Nachrichten spricht man von nachrichten-orientierter Kommunikation.

Im Vergleich beim Aufruf einer Funktion oder Methoden, die auf einem Client abgespeichert sind, spricht man von entfernter Funktionsaufrufe (entfernte Methodenaufrufe), wenn Daten verarbeitet werden oder wenn sie eintreffen, spricht man von stream-orientierter Kommunikation.

synchron vs. asynchron

Ein Nachrichtenautausch kann entweder synchron oder asynchron passieren. Bei einem synchronen Austausch wird die Operation begonnen, wenn der Sender die Nachricht initiert hat und der Empfänger bereit, ist die Nachricht zu empfangen. Bei einem asynchronen Nachrichtenaustauch ist es unabhängig davon, ob der Sender bereit ist oder nicht.

Semantik der Nachrichtenübermittlung

- no-wait-send
 - Der Sendeprozess wartet lediglich, bis die Nachricht im Transportsystem zum Absenden bereitgestellt ist.
- synchronization send
 - Der Sendeprozess wartet, bis die Nachricht vom Empfangsprozess entgegengenommen worden ist.
- remote-invocation send
 - Der Sendeprozess wartet, bis die Nachricht vom Empfangsprozess verarbeitet und beantwortet worden ist.

transient vs. persistent

Die Datenübertragen in einem Netzwerk kann transient sein (Message Passing), das heißt, beide Kommunikationspartner müssen online sein, weil das Kommunikationssystem Nachrichten nur solange speichert, wie die sendende und die empfangene Operation ausgeführt wird. Unter Persistent (Message Queueing), versteht man, dass Kommunikationssystem Nachrichten speichert bis diese vollständig an den Empfänger ausgeliefert wurden.

Musterlösungen einer Datenübertragung kann request/response(A sendet an B, B sendet an A) sein, oneway(A sendet an B, A sendet an B), batching(Zusammenfassung von oneway Nachrichten) und publish/subscribe. Daten können durch zwei verschiedene Möglichkeiten interoperable übertragen werden, nämlich Daten werden ganz einfach in ein maschinenunabhängiges Format transformiert, oder der Empfänger muss sich um eine notwendige Konvertierung kümmern. Im ersten Fall müssen beide Kommunikationspartner die Daten so umwandeln, sodass diese für sie verständlich sind und im zweiten Fall spezifiziert der Sender den Datentyp aus einer Liste von vorgegebenen Datentypen. [8]

Message Oriented Middleware

Message Oriented Middleware ist eine Softwareinfrastruktur, die durch asynchrone Verbindung (nicht im klassischen Sinne, sondern im Sinne von Kommunikationsbeziehungen) charakterisiert ist und die sich mittels mehreren Systeme durch Nachrichten miteinander verbindet. Protokolle für MOM wären zum Beispiel: AMQP, STOMP, OpenWire, Java Message Service, XMPP, REDIS und MQTT.

Im Unterricht wurde besonders auf das Protokoll MQTT Rücksicht genommen, weil es aktuell ist. MQTT ist ein Protokoll das ursprünglich von IBM zur Überwachung von Ölpipelines eingesetzt wird. Das Protokoll ist sehr leichtgewichtig gehalten, weil eine große Datenmenge mittels einfachem Protokoll übertragen werden soll.

Das Protokoll basiert auf einem publish/subscribe Ansatz und die Idee dieses Protokolls ist, dass es kompatible mit anderen Programmiersprachen, wie C++, Java, .Net, Python, PHP usw. ist. Der Aufbau des Protokolls ist hierarchisch, wie unter Linux der Verzeichnisbaum.

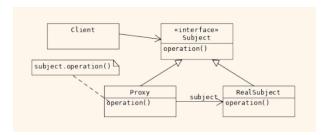
Der Vorteil ist der, dass man durch den hierarchisch Topic Aufbau, nur die Daten erhält, die man auch zwingend anfordert, bei etage1/wohnzimmer/bekommt man nur alle Daten vom Wohnzimmer aus der ersten Etage und wenn man alle Daten von der ersten Etage möchte, fordert man mittels /etage1/ diese an. Wichtige Charakteristika sind auch Themen, wie Quaility of Service, Last Will and Testament, Retained Message und Authentifizierung.

Entfernte Funktionsaufrufe

Unter Remote Procedure Call (RPC) versteht man, dass nach dem Funktionsaufruf der Prozess, der durch den Aufruf gestartet wird, auf einem anderem Host im lokalen Netzwerk gestartet wird. Die Zugriffstransparenz kann bei nachrichtenorientierter Kommunikation nicht erfüllt werden, wenn lediglich eine Operation am Server ausgeführt werden soll. Dieses Konzept findet Anwendung auf Basis von Proxy-Pattern.

Proxy-Pattern

Elemente des Proxy-Patterns sind: Client-Objekt, Client Stub(Proxy), Server Stub(Sekeleton), Server-Objekt



Die Vorgehensweise sieht folgendermaßen aus: Ein User möchte auf einem Objekt eine Methode aufrufen. Er ruft die Methode nicht direkt auf dem Objekt auf, sondern der Client verwendet ein Interface. Die Implementierung des Interface kann entweder eine abstrakte Klasse sein oder ein Interface, das vorgibt, welche Methoden definiert werden sollen bzw. zur Verfügung stehen. Zusätzlich gibt es noch eine Klasse Proxy und RealSubject, auf denen die Operation, die von oben vererbt wird, ausgeführt wird. Im Remote Proxy Pattern ruft ein Client mit dem Interface auf dem Proxy Objekt einer Operation auf. Diese Proxy Objekt dient als Stellvertretung des realen Objekts. Das Proxy Objekt baut nach der Ausführung der Operation eine Verbindung zu dem wirklichen Objekt auf und über diese Verbindung wird ein Protokoll abgewickelt. Bei der Übertragung werden sämtliche Informationen bezüglich des Funktionsaufrufes wie zum Beispiel Eingangsparameter, Ausgabeparameter oder Funktionsname mit übertragen.

Nach der Ausführung wird das Resultat des Objekts anhand des Protokolls zurück zum Proxy Objekt und dann zum Client zurückgesendet. Der Aufruf wirkt wie ein lokaler Aufruf, jedoch funktioniert dies über das verwendete Netzwerk. Das Sekeleton ist zuständig, die Kommunikation zwischen dem Proxy und dem RealSubject abzuwickeln.

Probleme, die bei der Umsetzung eines Proxy-Patterns auftreten könnten sind vor allem Interoperabilitätsprobleme (Probleme die beim Zusammenspiel zwischen verschiedener Systeme, Techniken oder Organisationen auftreten), call-by-refernce, Behandlung von Excpetions, die Transparenz kann nicht gewährleistet werden und die Behandlung von Threads und Prozessen erfolgt nur serverseitig, Client findet den Server nicht, Client stürzt nach dem senden der Nachricht ab, Nachricht geht verloren, Server stürzt ab, Antwort geht verloren, Client stürzt ab, bevor diese die Antwort bekommt.

Aufrufvarianten

- synchrone Funktionsaufrufe: remote-invocation send
- synchrone Prozeduraufrufe: synchronization send
- asynchrone Funktionsaufrufe: no-wait send
- asynchrone Prozeduraufrufe: no-wait send

Stream-orientierte Kommunikation

Stream-orientiert Kommunikation bezeichnet die gleichzeitige Übertragung und Wiedergabe von Video- und Audiodaten über ein Netzwerk. Dabei werden Streams von Daten versendet, keine Nachrichten, sondern nicht abgeschlossene Informationseinheiten. Den Vorgang der Datenübertragung selbst nennt man Streaming und übertragene Programme werden als Livestream oder kurz Stream bezeichnet. Streaming-Media, das über das WWW bzw. HTML angestoßen wurde, wird auch Webradio oder Web-TV genannt. Im Gegensatz zum Herunterladen ist das Ziel beim Streaming, nicht eine Kopie der Medien beim Nutzer anzulegen, sondern die Medien direkt auszugeben, anschließend werden die Daten verworfen.

Die Wiedergabe von Programmen über einen Livestream unterscheidet sich meist vom klassischen Rundfunk. Während beim Rundfunk an eine unbestimmte Anzahl Empfänger zugleich gesendet wird, handelt es sich beim Streaming meist jeweils um eine Direktverbindung zwischen dem Server des Senders und dem Client jedes einzelnen Benutzers. Die Verbreitung erfolgt oftmals über Streaming-Portale und internetbasierte Mediatheken. [9]

3.7 TCP/IP

Das Transmissioncontrollprotokoll und Internet Protokoll ist eine Menge von Kommunikationsprotokollen, die für den Verbindungsaufbau zu einem Netzwerk verwendet werden. TCP/IP kann auch als Kommunikation in einem Intranet(Firmen internes Internet) oder Extranet(betriebsinternes Computersystem, das für bestimmte externe Benutzergruppen geöffnet ist) eingesetzt werden. TCP/IP ist eine Reihe von Regeln und Verfahren wie der Datenaustausch abgehalten werden soll, dabei sind TCP/IP die Hauptprotokolle. TCP/IP definiert, wie Daten über das Internet übertragen werden, indem eine Ende zu Ende Kommunikation bereit gestellt wird. Weiters ist das Protokoll zuständig für die Aufteilung der Daten in Pakete, Adressierung, Übertragung, Weiterleitung und auch, dass die Daten beim richtigen Empfänger ankommen.

TCP

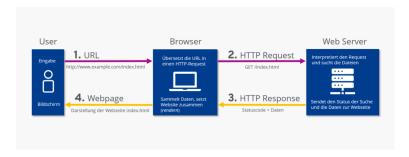
TCP bestimmt, wie Daten über ein Netzwerk geschafft werden können und zusätzlich auch wie Daten in Pakete aufgeteilt werden, sodass diese daraufhin über das Internet übertragen werden können und an der Zieladresse wieder in richtigen Reihenfolge zusammenfgefügt werden können. In der Internetprotokollfamilie bildet TCP gemeinsam mit UDP und SCTP die Gruppe der Transportprotokolle, die nach dem OSI-Modell in der Netzwerk-Architektur auf der Transportschicht eingestuft werden. Da das TCP-Protokoll in fast allen Fällen auf dem Internet Protocol (IP) aufsetzt und diese Verbindung die Basis für den Großteil aller öffentlichen und lokalen Netzwerke und Netzwerkdienste bildet, ist häufig auch vom TCP/IP-Protokollstapel die Rede, wenn im eigentlichen Sinne die Internetprotokollfamilie gemeint ist.

\mathbf{IP}

Wohingegen IP fixiert, wie jedes einzelne Datenpaket adressiert und geroutet wird, dass diese zum richtigen Empfänger geleitet werden. Deshalb bedarf es einer Möglichkeit das Netzwerk physikalisch (Topologie) und auch logisch (Adressierung) zu strukturieren. Innerhalb von TCP/IP übernimmt das Internet Protocol (IP) die logische Adressierung von Netzwerken und deren Teilnehmern. Dabei gelangen Datenpakete nur in das Netz, in dem sich das Ziel befindet. Die Verfahren der Adressierung sind zum Beispiel fest definierte Netzklassen, Subnetting und CIDR. Jeder Gatway im Netzwerk überprüft die IP-Adresse, um festzustellen, wohin die Nachricht weiter geleitet werden. Ein Gateway ist ein Netzwerk-Knoten, der als Eingang zu einem anderen Netzwerk dient. Internet-Knoten können entweder Gateway-Knoten oder Host-Knoten sein.

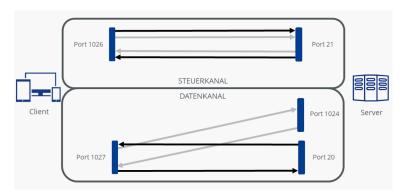
HTTP/HTTPS

Dieses Protokoll ist zuständig für die Kommunikation zwischen Client(Browser) und Webserter. Wenn ein Benutzer im Browser eine Internetadresse aufruft, wird ein Request an den WebServer versendet. Dieser Server sucht die Daten, auf denen angefragt wurde und sendet die Daten der Webseit per Repsone dem Benutzer(Browser) zurück. Der WebBrowser sammelt die Daten zusammen und setzt diese zu der entgültigen Webseite zusammen. Bei HTTPS bassiert diese Kommunikation geschüzt und verschlüsselt.



FTP/SFTP

Das Protokoll ist dafür entwickelt worden, um mit Befehlen Downloads und Uploads im Zusammenhang mit dem entsprechenden Server durchzuführen. So kann man Dateien von dem eigenen Gerät (PC, Smartphone usw.) auf einen Server übertragen und auch umgekehrt. Per FTP können Dateien auch vom Server auf das Gerät heruntergeladen werden. Das File Transfer Protocol findet Anwendung beim Erstellen von Websites, weil mit dem FTP-Zugang können HTML-Dateien auf den Server übertragen werden. Außerdem können Betreiber von Websites Mediendateien für Besucher der Homepage bereitstellen. SSH File Transfer Protocol (SFTP) hingegen verwendet die Secure Shell für die sichere Übertragung von Dateien. Auch hierbei ist die Verbindung verschlüsselt.



TCP/IP-Modell

• Netzzugangsschicht

 Die Netzzugangsschicht ist zuständig, für die Verknüpfung von verschiedenen Subnetzen und verbindet so zum Beispiel das heimische WLAN per Router mit dem Internet.

• Internetschicht

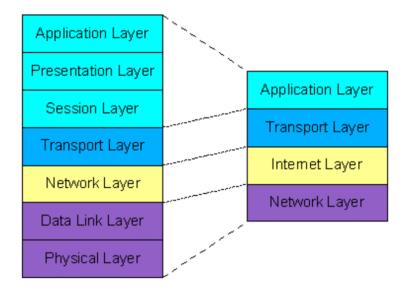
 Das Internetprotokoll ist an diese Schicht gerichtet, weil dadurch die Daten an das richtige Ziel gesendet werden sollen.
 Über die IP-Adresse werden die Datenpakete durch das Netzwerk geroutet.

• Transportschicht

– In diese Schicht kommt das Protkoll TCP zum Vorschein. Das Protokoll ermöglicht die Ende-zu-Ende-Kommunikation. Es ist also verantwortlich für die Verbindung zwischen zwei Geräten. Neben TCP gehört auch UDP in diese Ebene.

• Anwendungsschicht

 Die Kommunikation der Programme über das Netzwerk wird in der obersten Schicht geregelt. Maßgeblich sind hier z.B. HTTP und FTP. Aber auch die E-Mail-Kommunikation mittels POP, SMTP funktioniert auf dieser Ebene.



4 Implementierung

In diesem Kapitel geht es grundsätzlich um die technische Realisierung der Aufgabenstellung. Im folgenden Abschnitt wird auch der Aufbau des Projekts beschrieben. Außerdem enthält dieses Kapitel auch die Dokumentation des Source Codes und wichtige Informationen bezgüglich Bibliotheken, die im Projekt verwendet wurden.

4.1 Projektstruktur

Das Projekt wird in drei wesentliche Verzeichnisse eingeteilt, nämlich declaration, documentation und source. In dem Verzeichnis declaration sind alle Unterlagen abgelegt, die als Projektinput dient. In diesen Dokumenten sind die genauen Vorgaben des jeweiligen Projekts festgehalten. Im Ordner documenation sind alle Dateien der theoretischen Ausarbeitung des Themas und der Realisierung des Projekt abgespeichert, wohingegen im source Verzeichnis alle Datein der technischen Realisierung abgesichert werden. Im Verzeichnis source gibt es drei Unterverzeichnisse dem build Ordner, indem alle generierten Datein abgespeichert werden, der include Ordern, indem alle Header-Datein abgelegt werden und der src Folger, in diesem sind die main.cpp Dateien und die dazugehörigen .cpp Dateien des .h Dateien. Das Projekt wird in Module eingeteilt. Das heißt, die Klassendefinition, Konstruktoren und Methodenprototypen von Client, SlaveServer und MasterServer stehen in der jeweiligen h-Datei. Die Methodendefinitionen, der dazugehörigen Klasse, wurden in der dazugehörigen cpp-Datei kodiert. Zusätzlichen Funktionen die für die Umsetzung des Projekts dringend notwendig waren, wurden in dem Modul utils declariert und definiert. Der Compiler generiert drei auszuführende Programm, dem Client, dem SlaveServer und dem MaterServer. Welche Zielsetzungen die einzelnen Programme haben, wird im jeweiligen Verzeichnis beschrieben. Da einige Source Code Abschnitte nicht verständlich und nachvollziebar sind, wurden alle Variablen, Funktionen, Klassen, Methoden und sonstiges gut dokumentiert.

Im unterem Verzeichnisbaum wird die Struktur des Projektes abgebildet

declarationenthält alle Dateien die für die Umsetzung wichtig sind		
issues.pdf		
projects.pdf		
documentation enthält alle Dateien der theoretiscenh Ausarbeitung		
MapReduce_System_Dokumentation.pdf		
MapReduce_System_Dokumentation.tex		
literatur.bib		
source enthält alle Dateien der praktischen Ausarbeitung		
build darin befinden sich alle automatisch generierten Datein		
include darin befinden sich alle h-Dateien		
client.h		
slaveserver.h		
masterserver.h		
utils.h		
srcdarin befinden sich alle cpp-Dateien		
client		
client.cpp		
main.cpp		
clientfile.txt		
masterserver		
masterserver.cpp		
main.cpp		
slaveserver		
slaveserver.cpp		
main.cpp		
data.json		
utils.cpp		

4.2 UML Klassendiagramm

ipadress : std::string port : std::string - SlaveServer(in ip: std::string, in pr: std::string, in spr: ushort, inout mx: std::mutex) + ~SlaveServer() + GetSlaveServer(in ip : std::string, in port : std::string, in lport : std::string, inout mx : std::mutex) : SlaveServer + GetDataMapSize(): int + Shuffle(): void Client ipadress : std::string MasterServer port : std::string - clients: std::string, std::map<std::string, std::string> datamap: std::string, int slaveserver : std::string, std::string - alphabet : char # connectioncounter : int - Client(in ip : std::string, in pr : std::string) # serverport : ushort - GetRandomString(): std::string # tabledata : std::string + GetClient(in ip : std::string, in pr : std::string) : Client # mux : std::mutex + GetMap(): std::map<std::string, int> # resultmap : std::string, int + GetDataMapSize(): int # maplist : std::map<std::string, int> + WriteIntoFile(in wordnum: int, in filename: std::string): void - SetMaps(): void + Map(in filename : std::string) : int # MasterServer(in pr : ushort, inout mx : std::mutex) # AddList(inout mapdic : std::map<std::string, int>) : void # SetTableData(in value : std::string, in valuecnt : int) : void + ~MasterServer() + GetTableData(): std::string + GetMasterServer(in port : std::string, inout mx : std::mutex) : MasterServer + GetServerPort(): ushort + GetMap(): std::map<std::string, int> + GetListLength(): int + GetConnectionCounter(): int + SetConnectionCounter(): void + ConvertStringtoMap(in transportstr : std::string) : void + InsertElementinMap(in value : std::string, in valuecnt : int) : void + PrintTable(in masterservername : std::string) : void + WriteIntoFile(in jsonfile : std::string) : void + Reduce(): void

SlaveServer

4.3 Client

Modulbeschreibung

Die Komponente Client ist eine ausführbare Datei und bildet den Input für die Datenverarbeitung des MapReduce-Systems. Wenn das Programm vom Benutzer gestartet wird, wird eine Verbindung zum jeweiligen Server aufgebaut. Wenn diese erfolgt, wird eine bestimmte Anzahl von Strings, die der Benutzer beim Aufruf mitübergibt, generiert und in eine Datei geschrieben. In der nächsten Phase durchforstet das Programm, die Datei zeilenweise durch und speichert die Datensätze in einer Art Dictionary ab(Key:Value). Der zufällig generierte String entspricht im Dictionary dem Key und der Value die Anzahl des Strings wie oft dieser in der Datei vorkommt. Dieser Part wird im MapReduce-System als Map Funktion bezeichnet. Zum Schluss wenn alle Daten im Dictionary abgespeichert sind, wird dieses in einem String konvertiert, um diesen daraufhin an dnm Server zu übertragen. Bei der Umwandlung des Dictionarys, werden den Key-Werten und Value-Werten Trennsymbole angehängt, sodass der Slaveserver die Zeichenkette aufteilen und weiters in ein Dictionary zurück umkonvertieren kann.

Kommandozeilenparameter

MapReduceSystem_Client
Usage: ./client [OPTIONS]

Options:

-h,--help Print this help message and exit
-n,--n TEXT REQUIRED name for the client
-i,--i TEXT ipadress for the client
-p,--p TEXT REQUIRED port to connect to
-f,--f TEXT:FILE filepath of the file

Klassenaufbau

```
class Client{
private:
//Variablen
    //IP Adresse des Clients
    string ipadress;
    //PORT des jeweiligen Servers
    string port;
    /*in dieser Map werden alle komprimierten Daten
    nach der Map Phase abgespeichert*/
    map<string, int> datamap;
    //Array dient für die Generierung von random strings
    const char alphabet[52];
//Konstruktor
    Client(string ip, string pr):ipadress{ip}, port{pr}{}
//Methoden
    //generiert eine zufälligen String und gibt diesen zurück
    string GetRandomString();
public :
//Methodena
    /*gibt ein Objekt vom Typ Client zurück,
    wenn Port und IP Adresse valid sind*/
    static Client *GetClient(string ip, string pr);
    //qibt einen Pointer des Objekts datamap zurück
    map<string, int>* GetMap();
    //gibt die Länge der Map zurück
    int GetDataMapSize();
    /*dabei werden zufällige String(Anzahl = wordnum)
    in die Datei(filename) geschrieben und abgespeichert*/
    void WriteIntoFile(int wordnum, string filename);
    //1 Phase des Map-Reduce Systems
    int Map(string filename);
};
```

4.4 SlaveServer

Modulbeschreibung

Diese Komponente bildete die Schnittstelle zwischen den Clients und dem Masterserver. Der SlaveServer hört auf einen Port ab und empfängt, jene Daten die ihm der Client sendet. Die Übetragungsdaten werden in Form von einem String übertragen, wobei die einzelnen Werte durch ein; getrennt werden. Wenn der Slaverserver von 2 unterschieldichen Clients Daten bekommen hat, werden die Strings zurück in eine Map konvertiert und in einer Map-List abgespeichert. Wenn sich zwei Maps in dieser Liste befinden, wird zu jedem Paar(also wenn immer 2 Maps in der Liste gespeichert sind) ein Thread gestartet. In jedem Thread werden die einzelnen Werte der Maps verglichen und verkleinert, d.h Durchführung der Shuffle Phase. Die resultierenden Daten werden dann in der Map resultmap abgespeichert. Danach wird die Map resultmap wieder in einem Übertragungsstring umgewandelt und an de Master Server (Port) versendet, der beim Aufruf des SlaveServers mitübergeben wurde. Auf Grund der parallelen Abarbeitung der Daten bietet dieses System eine hohe Effizienz. Wie im Modul Client wird die Map am Ende zu einem Übertragungsstring umgewandlet und dem MasterServer versendet.

Kommandozeilenparameter

MapReduceSystem_SlaveServer
Usage: ./slaveserver [OPTIONS]

Options:

-h,--help Print this help message and exit
-n,--n TEXT REQUIRED name for the slaveserver
-i,--i TEXT ipadress for the server
-p,--p TEXT REQUIRED port to connect to
-s,--s TEXT REQUIRED serverport
-c,--c INT the maximum of clients

Klassenaufbau

```
class SlaveServer : public MasterServer{
private:
//Variablen
    string ipadress; //IP Adresse des SlaveServers
    string port;
                     //PORT des jeweiligen Servers
//Konstruktor
    SlaveServer(string ip, ...):MasterServer(spr, mx){
        ipadress = ip;
       port = pr;
    }
public:
//Destruktor
    ~SlaveServer(){}
//Methoden
    /*gibt ein Objekt vom Typ SlaveServer
    zurück, wenn Port und IP Adresse valid sind*/
    static SlaveServer* GetSlaveServer(string ip, ...);
    //qibt die Länger der Map resultmap zurück
    int GetDataMapSize();
    //2 Phase des Map-Reduce Systems
    void Shuffle();
};
```

4.5 MasterServer

Modulbeschreibung

Der MasterServer ist die wichtigste Komponente des Projekts, weil dieser hat am Ende des Prozederes die Aufgabe, die Daten, die er von dem Slave Server bekommt, so klein wie möglich zu komprimieren. Diese Phase wird Reduce genannt und am Ende dieser Phase kommen keine doppelten Datensätze mehr vor. Der Master Server hört wie auch der Slave Server auf einem Port ab und wartet so lange bis er einen Request von einem Slave Server bekommt. Wenn dieser von zwei unterschiedlichen Slave Server Daten bekommen hat, wird immer wieder Threads gestaterte die unabhängig voneinander die Daten der Slave Server verkleinern und in der resultmap abspeichern. Nach der Durchführung der Reduce Phase, wurden alle Daten der Clients komprimiert, was bedeutet es existieren in der Datenmenge keine doppelten Wert mehr.

Kommandozeilenparameter

MapReduceSystem_MasterServer
Usage: ./masterserver [OPTIONS]

Options:

-h,--help Print this help message and exit
-n,--n TEXT REQUIRED name for the masterserver
-p,--p TEXT REQUIRED serverport
-c,--c INT the maximum of slaveserver
-j,--j TEXT:FILE write reduced data in json-file
-t,--t print a table about the reduced data

Klassenaufbau

```
class MasterServer{
private:
//Variablen
    //map dient zur Ausgabe der Tabelle(tabulate)
    map<string, map<string, string>> clients;
    //map dient zur Ausgabe der Tabelle(tabulate)
    map<string, string> slaveserver;
//Methoden
    /*dabei werden die Daten des Strings tabledata,
    der für die Ausgabe der Tabelle auf der Console von Relevant sind,
    in den jeweiligen Maps abgespeichert*/
    void SetMaps();
protected:
//Variablen
    //max. Anzahl der SlaveServer
    int connectioncounter{0};
    //Port des MasterServers
    unsigned short serverport;
    //notwendiger Übertragungsstring für Tabelle(tabulate)
    string tabledata = "";
    //Mutex Objekt
    mutex &mux;
    /*in dieser Map werden alle komprimierten Daten
     nach der Reduce Phase abgespeichert*/
    map<string, int> resultmap;
    //Liste aller Maps(SlaveServer)
    list<map<string, int>> *maplist;
//Konstruktor
    MasterServer(unsigned short pr, mutex &mx) : serverport{pr}, mux{mx}{
        maplist = new list<map<string, int>>();
    }
//Methoden
    //fügt eine neue Map in die Liste maplist hinzu
    void AddList(map<string, int> *mapdic);
    // erweitert den String tabledata
    void SetTableData(string value, int valuecnt);
```

```
public:
//Destruktor
    ~MasterServer(){
        delete maplist;
    }
//Methoden
    //qibt den String tabledata zurück
    string GetTableData();
    // gibt ein Objekt vom Typ MasterServer zurück, wenn Port valid sind
    static MasterServer* GetMasterServer(string port, mutex &mx);
    //qibt den Port des Servers zurück
    unsigned short GetServerPort();
    //qibt den Pointer des Objekts resultmap zurück
    map<string, int>* GetMap();
    //gibt die Größe der Liste zurück
    int GetListLength();
    //gibt den Wert der Varible connectioncounter zurück
    int GetConnectionCounter();
    //erhöht die Variable connectioncounter um 1
    void SetConnectionCounter();
    /*konvertiert die Daten des Transport strings in eine Map
    und fügt die angelegte Map in die Liste hinzu*/
    void ConvertStringtoMap(string transportstr);
    //fügt Datensätze in die resultmap ein
    void InsertElementinMap(string value, int valuecnt);
    /*wird aufgerufen wenn Benutzer das Programm MasterServer
    mit -t startet, dabei wird am Ende der Reduce Phase eine Tabelle in
    der Console ausgegeben bezgl. den überarbeiteten Daten*/
    void PrintTable(string masterservername);
    /*wird aufgerufen wenn Benutzer das Programm MasterServer
    mit -j startet, dabei wird am Ende der Reduce Phase alle resultierenden
    Daten in ein JSON File geschrieben*/
    void WriteIntoFile(string jsonfile);
    //3 Phase des Map-Reduce Systems
    void Reduce();
};
```

4.6 utils

Funktionen

Im folgendem Kapitel werden noch Funktionen festgehalten, die für die Umsetzung von Wichtigkeit sind.

```
/*
-Name: GetRandomNum
-Beschreibung: liefert eine zufällige Zahl von start bis end
-Input: int start, int end
-Output: int
*/
int GetRandomNum(int start, int end){
    random_device rd;
    mt19937 gen{rd()};
    uniform_int_distribution<> dis{start, end};
    int num = dis(gen);
    return num;
}
/*
-Name: PORTIsValid
-Beschreibung: überprüft ob der mitübergebene PORT valid ist (korrekt ist)
-Input: string port
-Output: bool
*/
bool PORTIsValid(string port){
    size_t pos;
    int num = stoi(port, &pos);
    if (pos != port.size() || port.length() != 4){
        return false;
    }
    if (num < 0 \mid \mid num > 65535){
        return false;
    }
    return true;
}
```

```
/*
-Name: IPIsValid
-Beschreibung: überprüft ob die mitübergebene
IP Adresse valid is (korrekt is)
-Input: string ip
-Output: bool
*/
bool IPIsValid(string ip){
    int c{0};
    char *ip_input = strtok(&ip[0], ".");
    while (ip_input != NULL){
        string ipstring = ip_input;
        size_t pos;
        int num = stoi(ipstring, &pos);
        if (pos != ipstring.size()){
            return false;
        }
        if (num < 0 | | num > 255){
            return false;
        }
        c += 1;
        ip_input = strtok(NULL, ".");
    if (c < 4){
        return false;
    }
    return true;
}
-Name: Search
-Beschreibung: überprüft ob der mitübergebene string in der Map enthalten ist
-Input: string value, std::map<std::string, int>* dic
-Output: bool
*/
bool Search(string value, std::map<std::string, int>* dic){
    if (dic->find(value) == dic->end()){
        return false;
    }
    return true;
}
```

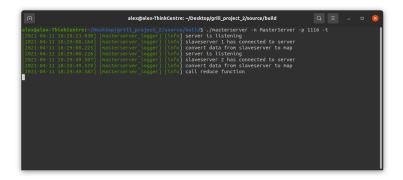
```
/*
-Name: Search
-Beschreibung: konvertiert die Map (dic Pointer auf das Objekt) zu einem string
-Input: std::map<std::string, int>* dic
-Output: string
string ConvertMaptoString(std::map<std::string, int>* dic){
    string dicstring = "";
    for (map<string, int>::iterator i = dic->begin(); i != dic->end(); ++i){
        dicstring += i->first;
        dicstring += ",";
        dicstring += to_string(i->second);
        dicstring += ":";
    }
    return dicstring;
}
/*
-Name: Print
-Beschreibung: Printed die Map(dic Pointer auf das Objekt)
-Input: std::map<std::string, int>* dic
-Output: void
*/
void Print(std::map<std::string, int>* dic){
    int counter{0};
    cout << "Data Map" << endl;</pre>
    for (map<string, int>::iterator t = dic->begin(); t != dic->end(); ++t){
        cout << "Data " << t->first << " " << t->second << endl;</pre>
        counter += 1;
    }
    cout << "Elements: " << counter << endl;</pre>
}
```

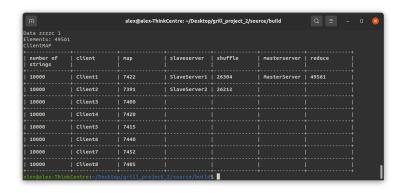
4.7 Konsolenausgabe

Client

Slave Server

Master Server





4.8 Verwendete Bibliotheken

4.8.1 asio

Asio ist eine plattformübergreifende C++-Bibliothek für Netzwerk- und Low-Level-I/O-Programmierung, die Entwicklern ein konsistentes asynchrones Modell mit einem modernen C++-Ansatz bietet. Asio bietet die grundlegenden Bausteine für C++-Netzwerke, Gleichzeitigkeit und andere Arten von Eingabe/Ausgabe Asio wird in allen Arten von Anwendungen eingesetzt, von Telefon-Apps bis hin zu den schnellsten Aktienmärkten der Welt.

Die meisten Programme interagieren auf irgendeine Weise mit der Außenwelt, sei es über eine Datei, ein Netzwerk, ein serielles Kabel oder die Konsole. Manchmal, wie z. B. bei Netzwerken, können einzelne E/A-Operationen sehr lange dauern, bis sie abgeschlossen sind. Dies stellt besondere Herausforderungen an die Anwendungsentwicklung. Asio stellt die Werkzeuge zur Verfügung, um diese langwierigen Operationen zu verwalten, ohne dass die Programme Gleichzeitigkeitsmodelle auf Basis von Threads und explizitem Sperren verwenden müssen. Die Asio-Bibliothek ist für Programmierer gedacht, die C++ für die Systemprogrammierung verwenden, bei der der Zugriff auf Betriebssystemfunktionen wie z. B. Netzwerke erforderlich ist. Obwohl sich Asio anfangs hauptsächlich auf Netzwerke konzentrierte, wurden seine Konzepte der asynchronen I/O auf andere Betriebssystemressourcen wie serielle Schnittstellen, Dateideskriptoren usw. erweitert. [1]

Im Besonderen verfolgt Asio folgenden Ziele:

Portability

Die Bibliothek sollte eine Reihe gängiger Betriebssysteme unterstützen und ein konsistentes Verhalten über diese Betriebssysteme hinweg bieten.

Scalability

– Die Bibliothek sollte die Entwicklung von Netzwerkanwendungen erleichtern, die auf Tausende von gleichzeitigen Verbindungen skalieren. Die Implementierung der Bibliothek für jedes Betriebssystem sollte den Mechanismus verwenden, der diese Skalierbarkeit am besten ermöglicht.

• Efficiency

- Die Bibliothek sollte Techniken wie Scatter-Gather-I/O unterstützen und es Programmen ermöglichen, das Kopieren von Daten zu minimieren.

- Model concepts from established APIs, such as BSD sockets
 - Die BSD-Socket-API ist weithin implementiert und verstanden und wird in vielen Literaturen behandelt. Andere Programmiersprachen verwenden oft eine ähnliche Schnittstelle für Netzwerk-APIs. Soweit dies sinnvoll ist, sollte Asio die bestehende Praxis nutzen.

• Ease of use

Die Bibliothek sollte eine niedrigere Einstiegshürde für neue Benutzer bieten, indem sie eher einen Toolkit- als einen Framework-Ansatz verfolgt. Das heißt, sie sollte versuchen, den zeitlichen Aufwand im Vorfeld auf das Erlernen einiger grundlegender Regeln und Richtlinien zu minimieren. Danach sollte ein Bibliotheksbenutzer nur noch die spezifischen Funktionen verstehen müssen, die verwendet werden.

• Basis for further abstraction

 Die Bibliothek sollte die Entwicklung anderer Bibliotheken ermöglichen, die eine höhere Abstraktionsebene bieten. Zum Beispiel Implementierungen von häufig verwendeten Protokollen wie HTTP.

4.8.2 CLI11

CLI11 bietet alle Funktionen, die man von einem leistungsstarken Befehlszeilenparser erwartet, mit einer schönen, minimalen Syntax und ohne Abhängigkeiten über C++11 hinaus. Es ist eine header-only, um die Einbindung in Projekte zu vereinfachen. CLI11 ist einfach für kleine Projekte zu verwenden, aber leistungsstark genug für komplexe Befehlszeilenprojekte und kann für Frameworks angepasst werden.

Die Bibliothek wird mit Travis-, AppVeyor-, Azure- und GitHub-Aktionen getestet und vom GooFit-GPU-Anpassungsframework verwendet. Es wurde von plumbum.cli für Python inspiriert. CLI11 bietet eine benutzerfreundliche Einführung in diese README-Datei, ein ausführlicheres Tutorial-GitBook, sowie eine von Travis generierte API-Dokumentation. Weitere Informationen zu aktuellen und früheren Versionen findet man im Changelog oder in den GitHub-Versionen. [3]

4.8.3 spdlog

spdlog ist eine sehr effiziente headeronly C++ Protokollierungsbibliothek. Sie bietet auch ebenfalls eine Python-ähnliche Formatierungs-API unter Verwendung der mitgelieferten fmt lib. spdlog verfolgt den Ansatz ïnclude what you need". Der Source Code sollte die Funktionen enthalten, die tatsächlich benötigt werden.

Den Programmierer wird eine funktionsreiche Formatierung mit der hervorragenden fmt-Bibliothek geboten. Im Projekt wird die Libary verwendet, damit die Logging Informationen in der Kommandozeile ausgegeben werden kann. Zusätzlich ist es auch möglich, die Logging Daten nicht nur auszugeben, sonder auch direkt in einem Log-File zu schreiben. [11]

4.8.4 json

In Sprachen wie Python fühlt sich JSON wie ein erstklassiger Datentyp an. Die Entwickler haben die ganze Operator-Magie des modernen C++ verwendet, um das gleiche Gefühl in einem c++ Projekt zu erzielen. Der gesamte Code besteht aus einer einzelnen Header-Datei json.hpp. Keine Bibliothek, kein Teilprojekt, keine Abhängigkeiten, kein komplexes Build-System. Die Klasse ist in Vanilla C++ 11geschrieben.

Alles in allem ist keine Anpassung der Compiler-Flags oder Projekteinstellungen erforderlich. Jedes JSON-Objekt hat einen Overhead und ein Aufzählungselement. Die Standardverallgemeinerung verwendet die folgenden C++-Datentypen: string für Zeichenfolgen, int64_t, uint64_t oder double für Zahlen, map für Objekte, vector für Arrays und bool für Boolesche Werte. json.hpp ist die einzige erforderliche Datei in single_include/nlohmann, jedoch muss sie im Projekt mit eingebunden werden.

Die Libary wurde in diesem Projekt verwendet, um die zusammengefassten Daten des Master-Server abzuspeichern. [6]

4.8.5 rang

rang only hängt von der C++ Standardbibliothek, dem Systemheader unist d.h unter Unix und den Systemheadern windows.h und io.h auf Windowsbasierten Systemen ab. Mit anderen Worten, man benötigt keine Abhängigkeiten von Drittanbietern. Diese Standardbibliothek ermöglich es den Output der Console zu formatieren. Dabei kann die Schriftart, Farbe und sonstige Eigenschaften bezüglich der Consolenausgabe konfigurieren. [10]

4.8.6 tabulate

tabulate ist eine reine headeronly-Bibliothek. Man legt ein Objekt Table an und kann mittels Table.add_rows neue Zeilen in der Tabelle hinzufügen. Die Tabelle kann mittels Table.format() formatiert werden, das ein Format-Objekt zurückgibt. Es können damit die Eigenschaften der Tabelle formatiert werden, z. B. Rahmen, Schriftstile, Farben usw. Auf Zeilen in der Tabelle greift man mitTabelle [row_index] zu. Dies gibt ein Zeilenobjekt zurück, für das man Row.format() auf ähnliche Weise aufrufen kann, um die Eigenschaften aller Zellen in dieser Zeile zu formatieren.

Die Bibliothek wurde verwendet, sodass am Ende des Programmes eine übersichtliche Tabelle ausgegeben werden kann, wie viele Daten in Struktur gebracht. [12]

5 Anwendungsfälle

```
./client -h
./slaveserver -h
./masterserver -h
```

Dadurch erhält man alle Information bezgl. der Kommandozeilenparameter

```
./client -n Client1 -p 1113
```

Startet den Client mit der IP Adresse 127.0.0.1 und versucht sich auf Port 1113 zum SlaveServer zu verbinden und sendet den SlaveServer die Daten(Result der Map Funktion) Der Port ist beim Aufruf des Programms zwingend notwendig. Es werden, ohne Aufruf von -w ÄNZAHL", 50 000 unterschiedliche strings in die Datei clientfile.txt geschreiben und folgedessen in der Map Funktion komprimiert.

```
./client -n Client1 -i 192.168.8.1 -p 1113
```

Startet den Client mit der IP Adresse 192.168.8.1 und versucht sich auf Port 1113 zum SlaveServer zu verbinden und sendet den SlaveServer die Daten(Result der Map Funktion)

./client -n Client1 -p 1113 -f "../Desktop/file.txt"

Startet den Client mit der IP Adresse 127.0.0.1 und versucht sich auf Port 1113 zum SlaveServer zu verbinden und sendet den SlaveServer die Daten(Result der Map Funktion) In diesem Fall werden die random generierten strings in die Datei file.txt abgespeichert.

./slaveserver -n SlaveServer1 -s 1113 -p 1116

Startet den SlaveServer mit der IP Adresse 127.0.0.1 und versucht sich auf Port 1116 zum MasterServer zu verbinden und sendet den MasterServer die Daten(Result der Shuffle Funktion). Der SlaveServer hört auf Port 1113 ab und baut eine Verbindung bei einem Request eines Clients auf. Der SlaveServer empfängt alle Daten der Clients. Die Ports sind beim Aufruf des Programms zwingend notwendig.

./slaveserver -n SlaveServer1 -s 1113 -p 1116 -i 192.168.8.1

Startet den SlaveServer mit der IP Adresse 192.168.8.1 und versucht sich auf Port 1116 zum MasterServer zu verbinden und sendet den MasterServer die Daten(Result der Shuffle Funktion)

./slaveserver -n SlaveServer1 -s 1113 -p 1116 -c 6

Der SlaveServer sendet nachdem von 6 Clients die Daten geshuffelt wurden, das Ergebniss an dem MasterServer auf Port 1116

./masterserver -n MasterServer1 -p 1116

Der MasterServer hört auf Port 1116 und empfängt alle Daten die ihm die SlaveServer zu kommen lassen

./masterserver -n MasterServer1 -p 1116 -c 3

Der MasterServer hört auf Port 1116 und empfängt alle Daten die ihm die SlaveServer zu kommen lassen. Nachdem er von 3 SlaveServer Daten bekommen hat wird die Reduce Funktion aufgerufen.

./masterserver -n MasterServer1 -p 1116 -t

Der MasterServer hört auf Port 1116 und empfängt alle Daten die ihm die SlaveServer zu kommen lassen am Ende gibt er in der Console eine Tabelle aus, die veranschaulicht in welcher Phase wie viele Daten komprimiert wurden.

./masterserver -n MasterServer1 -p 1116 -j ../src/build/test.json

Der MasterServer hört auf Port 1116 und empfängt alle Daten die ihm die SlaveServer zu kommen lassen am Ende werden die komprimierten Daten in ein JSON-File geschrieben.

6 Schlusswort

Die gesamte Ausarbeitung meines Projekts hat mir persönlich sehr gut gefallen, weil ich sehr viele neue programmiertechnische Kenntnisse erlernt habe. Gleichzeitig habe ich aber auch vieles zu den Thematiken "Datenübrtragung", "TCP/IP", "Parallel Programmingund vorallem zum Thema MapReduce gelernt. Ich bedanke mich sehr herzlich bei meinem Professor Günter Kolousek, der die Idee hatte, statt der praktischen Arbeit und dem Theorietest solch eine Arbeit zu machen. Das Ausarbeiten wie auch das Programmiern hat mir sehr viel Freude bereitet, weil ich meine eigenen Kenntnisse anwenden konnte. Auch bei Problemen oder Fragen war Herr Professor immer sehr hilfsbereit und war jederzeit erreichbar. Mit diesem Projekt habe ich zunehmend Erfahrungen, Kenntnisse und vorallem Wissen sammeln können, bezgüglich Threads, Prozesse, Loggin, Kommunikation zwischen Server und Clients, SPDLOG, CLI11, Tabulat usw. Zum Schluss möcht ich nochmals daraufeingehen, dass mir die Realisierung des Projekt "MapReduce-Systemsehr viel Freude gemacht hat, obwohl manche Problem ziemlich schwierig zu lösen waren.

Literatur

- [1] asio. asioC++Libary. besucht am 15.01.2021. 2021. URL: https://think-async.com/Asio/asio-1.18.1/doc/.
- [2] BigDataInsider. Was ist MapReduce? besucht am 24.02.2021. 2021. URL: https://www.bigdata-insider.de/was-ist-mapreduce-a-624936/.
- [3] cli11C++Libary. besucht am 15.01.2021. 2021. URL: https://github.com/CLIUtils/CLI11.
- [4] Big Data. *MapReduce-System*. besucht am 24.02.2021. 2021. URL: https://www.bigdataschool.ru/wiki/mapreduce.
- [5] ionos. TCP/IP. besucht am 18.01.2021. 2021. URL: https://www.ionos.at/.
- [6] json++Libary. besucht am 15.01.2021. 2021. URL: https://github.com/nlohmann/json.
- [7] Günter Kolousek. 19_parallel_programming. selfmade_online_webinar. besucht am 14.03.2021. 2021.
- [8] Günter Kolousek. 25_communication_1. selfmade_online_webinar. besucht am 02.03.2021. 2021.
- [9] Günter Kolousek. 25_communication_2. selfmade_online_webinar. besucht am 09.03.2021. 2021.
- [10] rang+Libary. besucht am 15.01.2021. 2021. URL: https://github.com/agauniyal/rang.
- [11] spdlog++Libary. besucht am 15.01.2021. 2021. URL: https://github.com/gabime/spdlog.
- [12] tabulate++Libary. besucht am 15.01.2021. 2021. URL: https://github.com/p-ranav/tabulate.
- [13] wikipedia. MapReduce-System. besucht am 24.02.2021. 2021. URL: https://de.wikipedia.org/wiki/MapReduce.